

SeineCrops

Suivi et classification des cultures par séries temporelles Sentinel-2 Plateaux de la Basse-Seine (Caux et Neubourg), Normandie

Document de cadrage - données open data

Documentation : CC-BY 4.0 · Code : MIT

Cartographier et suivre l'évolution des cultures d'un territoire agricole à partir de séries temporelles d'images Sentinel-2, en s'appuyant sur le RPG comme vérité terrain, pour **classer les cultures par apprentissage automatique et détecter les parcelles dont le couvert diverge de leur déclaration**.

L'ensemble reproduit à échelle réduite la logique du dispositif opérationnel **3STR**

1. Contexte & problématique

Un besoin opérationnel, déjà institutionnalisé

Le suivi des cultures par télédétection n'est pas un sujet prospectif.

Depuis la campagne 2023, la politique agricole commune (PAC) impose à tous les états membres un Système de Suivi des Surfaces en temps réel (3STR), mis en œuvre en France par l'Agence de Services et de Paiements (ASP, asp.gouv.fr).

Ce dispositif analyse en continu les images des satellites Sentinel (opérés par Copernicus Data Space Ecosystem) pour reconnaître le couvert de chaque parcelle, suivre son évolution sur la campagne et alerter l'exploitant lorsque le couvert observé diverge de sa déclaration avec trois restitutions (juillet, août, septembre) et un « droit à l'erreur ».

Le Registre Parcellaire Graphique (RPG) fournit, en open data, les contours et la culture déclarée de chaque parcelle : c'est la donnée terrain de référence.

Le présent projet reproduit, à échelle réduite et en open source, la logique d'un système opérationnel de type 3STR.

La valeur visée est l'ingénierie de bout en bout :

acquisition → base spatio-temporelle → modèle → API → cartographie

Problématique

Comment construire une chaîne reproductible et open source qui, à partir de séries temporelles Sentinel-2 croisées au RPG, (a) classe automatiquement les cultures d'un territoire et (b) signale les parcelles dont le profil temporel diverge de leur culture déclarée tout en quantifiant l'incertitude à la manière d'un dispositif de suivi opérationnel (3STR) ?

Limites assumées

Ce projet reproduit la logique du 3STR mais en hérite aussi des limites, assumées et documentées :

- **Optique seule (pas de fusion radar).** Les systèmes opérationnels combinent souvent optique (Sentinel-2) et radar (Sentinel-1) pour s'affranchir des nuages. Ce projet se limite à Sentinel-2 : la couverture nuageuse normande est traitée par masquage SCL, composite temporel et indicateur de confiance.
- **Résolution grossière (10–20 m).** Comme le 3STR, la chaîne ne distingue ni les petites parcelles ni les cultures en mélange, c'est une limite intrinsèque de la donnée.

2. Parties prenantes & pertinence

Parce qu'il reproduit la logique d'un dispositif opérationnel réel, le projet « parle » à plusieurs familles d'acteurs.

Famille	Acteurs	Intérêt
Institutionnels	ASP, IGN, MASA + DRAAF, CNES (THEIA), CESBIO	Analogue direct du 3STR ; l'IGN produit RPG/BD TOPO/LiDAR ; CESBIO porte la chaîne iota2 d'occupation du sol Sentinel-2
Instituts techniques agricoles	Arvalis (service Farmstar), Terres Inovia, ITB, Acta, INRAE	Travaillent le suivi et la phénologie des cultures présentes sur la zone
Profession agricole	Chambres d'agriculture (APCA, Normandie), coopératives normandes (NatUp, Agrial)	Utilisatrices de RPG/géomatique pour le diagnostic de territoire et le conseil en agriculture de précision
Agritech & assurance	Airbus DS, CLS, Kermap, Sencrop, Agdatahub, Groupama, Pacifica	Débouché privé EO L'assurance paramétrique
Eau Environnement	Agences de l'eau AESN, syndicats de bassin versant, aires d'alimentation de captage	Croisent RPG et assolements pour le risque nitrates (en particulier en Pays de Caux karstique)

3. Objectifs

Objectif général : produire une chaîne reproductible, de la donnée brute à la carte interactive, qui classe les cultures, signale les divergences et caractérise la phénologie sur une zone agricole.

Objectifs spécifiques

1. Constituer une base spatio-temporelle PostGIS reliant parcelles RPG et indices de végétation Sentinel-2.
2. Quantifier la disponibilité réelle de Sentinel-2 sur l'AOI, nombre de scènes exploitables par mois (filtre cloudCover < 20 %), garde-fou méthodologique et premier résultat publiable.

3. Calculer, par parcelle, des profils temporels d'indices (NDVI, NDWI, EVI) avec masque nuages.
4. Entraîner et évaluer un modèle de classification des cultures (baseline Random Forest → option deep learning 1D-CNN/LSTM).
5. Mettre en place une détection de divergence / anomalies par classe (parcelles au profil aberrant).
6. Extraire des métriques de phénologie de surface par parcelle et par zone : début (SOS), pic (POS), fin (EOS) et longueur de saison.
7. Exposer les résultats via une API et une carte web interactive (clic parcelle → profil temporel + statut).
8. Documenter et publier (cadrage, méthode, code) en open license.

4. Questions d'ingénierie & critères de validation

Le projet se positionne en démonstration d'ingénierie opérationnelle.

Il est piloté par des questions d'ingénierie assorties de critères de validation mesurables. Les seuils chiffrés sont indicatifs, à ajuster après la première itération.

Question d'ingénierie	Critère de validation (mesurable)
QI1 — Robustesse au manque d'observations. Profil exploitable malgré les trous nuageux ?	Profil reconstruit pour ≥ 90 % des parcelles, avec indicateur de confiance (% d'observations valides). Dégradation documentée selon ce taux.
QI2 — Qualité de classification. Le modèle sépare-t-il les cultures cibles ?	F1 macro $\geq 0,80$ sur les grandes cultures ; matrice de confusion publiée ; F1 par classe reporté (y compris classes minoritaires).
QI3 — Baseline vs deep learning. Le DL justifie-t-il sa complexité ?	Gain de F1 du DL sur la baseline mesuré et tracé ; à performance équivalente, on conserve le modèle le plus simple.
QI4 — Détection de divergence (cœur 3STR). Les alertes sont-elles fiables ?	Taux de fausses alertes (précision) et rappel estimés sur échantillon contrôlé ; anomalies interprétées (erreur RPG / culture intermédiaire / stress).
QI5 — Absence de fuite spatiale. L'évaluation reflète-t-elle la généralisation ?	Split spatial par blocs (et non aléatoire) ; écart train/test sur emprises disjointes documenté.
QI6 — Reproductibilité & industrialisation. Un tiers peut-il rejouer la chaîne ?	Exécution complète via commande unique / DAG ; tests CI au vert ; temps de traitement et latence API mesurés.

Résultats attendus (à confirmer par les QI) :

Les grandes cultures sont plus séparables que les prairies et cultures minoritaires (QI2).

La fiabilité du profil et le taux de fausses alertes se dégradent sur les parcelles à forte couverture nuageuse (QI1, QI4)

5. Périmètre

Zone d'étude : une fenêtre à cheval sur l'**est du Pays de Caux et le plateau du Neubourg (Eure)**, de part et d'autre de la Seine. On reste 100 % en Normandie, on maximise l'openfield grandes cultures + lin, et on capte un léger gradient de nébulosité côte → intérieur exploitable pour l'indicateur de disponibilité S2. On exclut le Pays de Bray (bocage, petites parcelles) et les fonds de vallées qui brisent la classification. Surface cible : de 500 à 1 500 km², 1 à 2 tuiles Sentinel-2.

Période : année culturale étendue — **septembre N → décembre N+1** (~16 mois), alignée sur la campagne RPG N+1. L'extension par rapport à octobre N → septembre N+1 referme deux trous phénologiques : implantation du colza (fin d'été) en tête, arrachage betterave / récolte maïs (automne) en queue.

Cultures cibles (≈ 6–8 classes), depuis les groupes RPG : blé tendre, orge, colza, maïs, betterave, lin (typique de Normandie), prairies, autres.

Dans le périmètre : disponibilité S2, traitement S2, indices, classification, détection de divergence, métriques de phénologie de surface (SOS/POS/EOS/longueur), API, carte web, documentation.

Hors périmètre : prévision de rendement, fusion radar Sentinel-1, datation des stades agronomiques nommés (modèle degrés-jours — cf. 10. Perspectives), production multi-territoires, temps réel.

6. Données (toutes open data)

Donnée	Source / accès	Rôle	Licence
Sentinel-2 L2A	Copernicus Data Space Ecosystem (OData/STAC/openEO/Sentinel Hub, OAuth)	Séries temporelles, indices, disponibilité	Copernicus (libre)
RPG (parcelles + culture)	geoservices.ign.fr (téléchargement + WFS RPG.LATEST)	Vérité terrain, géométries	Licence Ouverte
Masque nuages	Bande SCL du L2A ou s2cloudless	Filtrage qualité	idem S2

Donnée	Source / accès	Rôle	Licence
Météo (optionnel)	meteo.data.gouv.fr ou ERA5 (Copernicus CDS)	Contexte stress, Base d'un futur modèle degrés-jours	Libre
BD TOPO / Ortho (optionnel)	geoservices.ign.fr	Habillage cartographique	Licence Ouvverte

Note : Un soin particulier doit être apporté aux dates calendaires du dernier RPG publié complet avant de sélectionner l'archive Sentinel-2.

7. Méthode (vue d'ensemble)

1. **Acquisition & disponibilité** : Requête catalogue CDSE sur la zone d'étude (AOI) + fenêtre + filtre nuages. Comptage des scènes exploitables par mois (cloudCover < 20 %). Récupération L2A (ou indices pré-calculés via openEO/Sentinel Hub).
2. **Pré-traitement** : Découpe AOI, masque nuages (SCL), calcul des indices (NDVI/NDWI/EVI).
3. **Agrégation zonale** : Statistiques par parcelle RPG et par date → table spatio-temporelle dans PostGIS.
4. **Construction des features** : Interpolation des trous, composite mensuel (~16 pas sur sept N → déc N+1), indicateur de confiance.
5. **Classification** : Split spatial train/test. Baseline Random Forest. Option DL (1D-CNN ou LSTM). Evaluation (matrice de confusion, F1 par classe).
6. **Détection de divergence / anomalies** : Score de distance au profil médian par classe. Seuils et interprétation.
7. **Phénologie de surface** : Ajustement de courbe (double-logistique / Savitzky-Golay) et extraction des métriques SOS/POS/EOS/longueur par parcelle, agrégées par zone et culture.
8. **Restitution** : API (profil + classe + score + métriques), carte web interactive, exports.

8. Architecture & stack technique

Le flux part de l'acquisition Sentinel-2 et de l'ingestion RPG vers une base PostGIS spatio-temporelle, qui alimente quatre traitements : classification (RF/DL), extraction des métriques phénologiques, requêtes SQL spatiales et API FastAPI. Les résultats sont restitués dans une carte web (MapLibre/Leaflet). L'ensemble est orchestré (Airflow ou Prefect) et outillé en CI/CD (GitHub Actions).

- **Base** : PostgreSQL + PostGIS (cœur du projet).
- **Traitement** : Python (Rasterio, GeoPandas, NumPy, scikit-learn ; PyTorch/Keras si DL).
- **Orchestration** : Airflow (ou Prefect en version légère).

- **API** : FastAPI. **Front** : MapLibre GL JS ou Leaflet.
- **Qualité logicielle** : Git, PR, tests (pytest), pré-commit, CI GitHub Actions.

9. Risques & mitigations

Risque	Impact	Mitigation
Couverture nuageuse forte (Normandie)	Trous dans les séries	Composite mensuel, interpolation, indicateur de confiance, multi-tuiles
Volume de données S2	Stockage / temps de calcul	Traitement cloud openEO/Sentinel Hub, AOI restreinte, indices au lieu de bandes brutes
Déséquilibre des classes RPG	Biais de modèle	Rééchantillonnage, métriques par classe, regroupement des classes rares
Fuite spatiale train/test	Surévaluation des performances	Split spatial par blocs / tuiles
Désalignement RPG / année S2	Vérité terrain fausse	Verrouiller RPG N+1 ↔ campagne sept N → déc N+1 dès le départ
Hétérogénéité de bordure de l'AOI	Bruit de classification	Exclure Pays de Bray et fonds de vallées du masque AOI

10. Perspectives

- **Volet agro-climatologie** : passer de la phénologie de surface (SOS/POS/EOS) à la datation de stades agronomiques nommés (germination, floraison, maturité, sénescence) via un modèle de degrés-jours alimenté en températures (ERA5-Land / Météo-France), puis comparaison à une climatologie pluriannuelle. Le produit Copernicus HR-VPP peut servir de référence.
- **Fusion Sentinel-1** (radar) pour combler les trous optiques.
- **Estimation de rendement** et extension multi-territoires.
- **Métadonnées INSPIRE** et flux OGC (WMS/WFS) sur les résultats.
- **Comparaison inter-annuelle des assolements** (lien avec les enjeux eau / nitrates).
- **Référence méthodologique** : aligner ultérieurement certains choix sur le système open source Sen4CAP (ESA, Sentinel-1/2 pour le suivi PAC) et ses ATBD — <https://github.com/Sen4CAP> — comme cadre de comparaison.